

**LAPORAN TUGAS BESAR DATA MINING
PENGELOMPOKKAN PROVINSI DI INDONESIA
BERDASARKAN INDEX PEMBANGUNAN MANUSIA
MENGUNAKAN ALGORITMA K-MEANS**



Dosen Pengampu : Achmad Bahauddin, S.T., M.T.

Disusun oleh :

Andiko Ramadani : 3337230003

Ussy Cantika : 3337230008

Ismet Maulana Azhari : 3337230014

**PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS SULTAN AGENG TIRTAYASA**

2025

DAFTAR ISI

DAFTAR ISI.....2

BAB 1. PENDAHULUAN.....3

1.1 Latar Belakang Masalah.....3

1.2 Rumusan Masalah.....3

1.3 Tujuan Penelitian.....3

1.4 Batasan Masalah.....4

BAB 2. LANDASAN TEORI.....5

2.1 Data Mining.....5

2.1.1 Tujuan dan Manfaat Data Mining.....5

2.1.2 Tahapan dalam Proses Data Mining.....6

2.1.3 Penerapan Data Mining dalam Konteks IPM.....7

2.2 Algoritma yang Digunakan.....7

2.2.1 Konsep Dasar Clustering.....8

2.2.1 Pengertian dan Prinsip Kerja K-Means.....8

2.2.3 Kelebihan dan Keterbatasan K-Means.....9

2.2.4 Penerapan K-Means dalam Penelitian.....9

2.2.5 Manfaat Penggunaan K-Means dalam Konteks IPM.....10

BAB 3. METODOLOGI PENELITIAN.....11

3.1 Data Science Methodology.....11

3.2 Data Preparation.....11

3.3 Modeling with K-Means.....12

3.4 Evaluation and Interpretation.....12

BAB 4. PENGUMPULAN DAN PENGOLAHAN DATA.....13

4.1 Pengumpulan Data.....13

4.2 Pengolahan Data.....14

4.2.1 Data Preparation.....14

4.2.2 Data Preprocessing.....15

4.2.3 Splitting Data.....18

4.2.4 Model Development.....18

4.2.5 Matrix Evaluation.....19

4.2.6 Performance Model Evaluation.....21

4.2.6 Visualization.....22

BAB 5. ANALISIS DAN PEMBAHASAN.....27

5.1 Hasil Klasterisasi K-Means.....27

5.2 Komposisi Klaster.....27

5.3 Perubahan IPM dan Dampaknya terhadap Klaster.....28

5.4 Visualisasi Hasil Klasterisasi.....28

5.5 Evaluasi dan Keterbatasan Model.....28

5.6 Pola Pembangunan Wilayah Berdasarkan Klaster.....29

BAB 6 KESIMPULAN DAN SARAN.....30

6.1 Kesimpulan.....30

6.2 Saran.....31

BAB 1. PENDAHULUAN

1.1 Latar Belakang Masalah

Indeks Pembangunan Manusia (IPM) merupakan indikator penting yang digunakan untuk mengukur keberhasilan suatu daerah dalam membangun kualitas hidup masyarakatnya. IPM mencakup tiga dimensi utama yaitu kesehatan (umur harapan hidup), pendidikan (rata-rata lama sekolah dan harapan lama sekolah), serta standar hidup layak (pengeluaran per kapita). Di Indonesia, setiap provinsi memiliki tingkat pembangunan manusia yang berbeda-beda, dipengaruhi oleh berbagai faktor sosial, ekonomi, dan geografis.

Ketimpangan pembangunan antar provinsi menjadi tantangan besar dalam upaya pemerataan kesejahteraan di Indonesia. Oleh karena itu, perlu dilakukan analisis terhadap pola-pola yang muncul dari data IPM untuk mengetahui kelompok-kelompok provinsi yang memiliki karakteristik pembangunan yang serupa. Salah satu metode yang efektif untuk melakukan pengelompokan data berdasarkan kesamaan karakteristik adalah algoritma **K-Means Clustering**.

Melalui penerapan algoritma K-Means pada data IPM provinsi di Indonesia, diharapkan dapat ditemukan pola-pola klaster yang dapat menjadi dasar bagi pengambilan kebijakan pembangunan yang lebih tepat sasaran. Pengelompokan ini dapat membantu pemerintah dalam merancang strategi pembangunan yang sesuai dengan kondisi masing-masing kelompok provinsi, sehingga dapat mempercepat tercapainya tujuan pembangunan nasional yang inklusif dan berkeadilan.

1.2 Rumusan Masalah

1. Bagaimana cara mengelompokkan provinsi-provinsi di Indonesia berdasarkan Indeks Pembangunan Manusia (IPM) menggunakan algoritma K-Means?
2. Berapa jumlah klaster optimal yang dapat dibentuk dari data IPM provinsi di Indonesia?
3. Apa karakteristik utama dari masing-masing klaster yang terbentuk?
4. Bagaimana hasil pengelompokan tersebut dapat digunakan untuk memahami perbedaan tingkat pembangunan manusia antarprovinsi?

1.3 Tujuan Penelitian

1. Menerapkan algoritma K-Means untuk mengelompokkan provinsi di Indonesia berdasarkan data IPM.
2. Menentukan jumlah klaster optimal yang paling sesuai untuk menggambarkan pengelompokan provinsi berdasarkan IPM.
3. Mengidentifikasi ciri-ciri atau karakteristik masing-masing klaster hasil pengelompokan.

4. Memberikan gambaran yang lebih jelas tentang perbedaan pembangunan manusia antar provinsi sebagai dasar dalam perumusan kebijakan pembangunan.

1.4 Batasan Masalah

1. Data yang digunakan terbatas pada data Indeks Pembangunan Manusia (IPM) provinsi-provinsi di Indonesia, yang meliputi indikator seperti *umur harapan hidup*, *rata-rata lama sekolah*, *harapan lama sekolah*, dan *pengeluaran per kapita*.
2. Metode pengelompokan yang digunakan dalam tugas besar ini hanya menggunakan algoritma K-Means Clustering tanpa membandingkan dengan metode clustering lainnya seperti DBSCAN atau Hierarchical Clustering.
3. Jumlah klaster ditentukan secara manual berdasarkan eksperimen internal dan tidak menggunakan metode otomatis seperti Elbow Method atau Silhouette Score secara mendalam.
4. Analisis hanya dilakukan pada level provinsi, sehingga tidak mencakup data yang lebih rinci seperti kabupaten/kota.
5. Visualisasi dan interpretasi hasil dibatasi pada hasil dari proses klasterisasi tanpa melakukan prediksi masa depan atau pemodelan lanjutan.

BAB 2. LANDASAN TEORI

2.1 Data Mining

Dalam era digital yang ditandai dengan ledakan informasi dan kemajuan teknologi komputasi, hampir semua aktivitas manusia menghasilkan data dalam jumlah yang sangat besar, baik dalam bentuk terstruktur maupun tidak terstruktur. Data ini berasal dari berbagai sektor, seperti pendidikan, kesehatan, ekonomi, dan pemerintahan. Namun, keberadaan data yang melimpah tidak otomatis memberikan nilai apabila tidak diolah dan dianalisis secara sistematis. Di sinilah peran **data mining** menjadi sangat penting.

Data mining merupakan proses eksplorasi dan analisis secara otomatis atau semi-otomatis terhadap sejumlah besar data untuk menemukan pola-pola tersembunyi, hubungan yang bermakna, serta informasi atau pengetahuan baru yang sebelumnya tidak diketahui dan berpotensi bernilai. Istilah ini sering kali disamakan dengan “penambangan data,” meskipun secara harfiah tidak berarti menggali data secara fisik, melainkan menggali *informasi tersembunyi* dari data yang telah tersedia.

Konsep ini tidak berdiri sendiri, melainkan merupakan bagian dari proses yang lebih luas yang dikenal sebagai **Knowledge Discovery in Databases (KDD)**. KDD adalah suatu kerangka kerja sistematis untuk memperoleh pengetahuan dari data yang mencakup tahapan-tahapan seperti pemilihan data, pembersihan data, transformasi, proses mining itu sendiri, evaluasi pola, dan penyajian hasil. Data mining merupakan tahap sentral dari KDD, yakni pada fase di mana teknik statistik, algoritma pembelajaran mesin, atau metode komputasi lainnya digunakan untuk mengekstraksi pola dari data yang telah disiapkan.

2.1.1 Tujuan dan Manfaat Data Mining

Tujuan utama dari data mining adalah untuk menemukan *informasi yang berguna* dari kumpulan data yang besar dan kompleks, yang tidak bisa dikenali hanya dengan pengamatan biasa. Informasi tersebut kemudian dapat digunakan untuk mendukung proses pengambilan keputusan, perencanaan strategi, serta prediksi terhadap kecenderungan di masa depan. Dalam konteks pemerintahan dan pembangunan, data mining bisa membantu dalam:

- Mengidentifikasi wilayah yang mengalami ketertinggalan dalam indikator-indikator pembangunan manusia.
- Menyusun strategi pembangunan yang berbasis data (*evidence-based planning*).
- Menganalisis kesenjangan antar daerah dalam hal kesehatan, pendidikan, dan ekonomi.
- Menyajikan hasil analisis secara visual agar mudah dipahami oleh pengambil kebijakan maupun masyarakat umum.

Dengan kata lain, data mining tidak hanya bersifat teknis, tetapi juga memiliki dimensi sosial dan kebijakan yang sangat kuat, karena hasilnya dapat menjadi dasar bagi intervensi pemerintah yang lebih tepat sasaran dan adil.

2.1.2 Tahapan dalam Proses Data Mining

Agar proses data mining menghasilkan keluaran yang bermakna, perlu dilakukan melalui tahapan-tahapan yang sistematis. Secara umum, tahapan-tahapan tersebut meliputi:

1. **Pemilihan Data (Data Selection)**

Tahap awal ini melibatkan pemilihan data yang relevan dengan permasalahan yang ingin dianalisis. Dalam penelitian ini, data yang digunakan merupakan data Indeks Pembangunan Manusia (IPM) dari Badan Pusat Statistik (BPS), dengan variabel utama yang mewakili tiga dimensi pembangunan: kesehatan (Angka Harapan Hidup), pendidikan (Rata-rata Lama Sekolah), dan ekonomi (Pengeluaran per Kapita). Pemilihan data ini sangat krusial karena akan menentukan relevansi dan keakuratan hasil pengelompokan.

2. **Pembersihan dan Integrasi Data (Data Cleaning and Integration)**

Data yang diperoleh sering kali tidak dalam kondisi siap pakai. Mungkin terdapat nilai yang hilang, data yang tidak konsisten, atau format yang berbeda-beda. Oleh karena itu, dilakukan proses pembersihan (cleaning) untuk menghilangkan atau memperbaiki anomali tersebut. Bila data berasal dari beberapa tabel atau sumber yang berbeda, maka perlu dilakukan integrasi agar data menjadi satu kesatuan yang bisa diolah secara menyeluruh.

3. **Transformasi Data (Data Transformation)**

Sebelum dianalisis, data yang sudah bersih kemudian ditransformasikan ke dalam bentuk yang sesuai untuk metode mining yang akan digunakan. Salah satu bentuk transformasi yang umum dilakukan adalah **normalisasi**, yaitu proses mengubah nilai-nilai numerik ke dalam skala yang seragam. Hal ini sangat penting, terutama ketika menggunakan algoritma seperti K-Means, yang sensitif terhadap perbedaan skala antar variabel.

4. **Proses Data Mining (Pattern Discovery)**

Ini adalah inti dari seluruh proses, di mana algoritma atau metode analisis diterapkan untuk menemukan pola atau struktur dalam data. Dalam penelitian ini, metode yang digunakan adalah **K-Means Clustering**, yaitu teknik pengelompokan data berdasarkan kesamaan karakteristik. Hasil dari tahap ini adalah terbentuknya sejumlah kelompok (klaster) provinsi yang memiliki karakteristik IPM yang relatif serupa.

5. **Evaluasi Pola dan Interpretasi Hasil (Pattern Evaluation and Interpretation)**

Pola atau klaster yang dihasilkan perlu dievaluasi untuk mengetahui apakah benar-benar bermakna dan sesuai dengan konteks masalah. Evaluasi dapat dilakukan secara kuantitatif (misalnya menggunakan metode *silhouette score*) maupun kualitatif (misalnya dengan membandingkan hasil klasterisasi dengan kondisi nyata di lapangan). Setelah itu, dilakukan interpretasi hasil agar dapat ditindaklanjuti lebih lanjut dalam bentuk rekomendasi kebijakan.

6. Penyajian Pengetahuan (Knowledge Representation)

Tahap akhir adalah menyajikan hasil dalam bentuk yang mudah dipahami, seperti grafik, peta tematik, tabel ringkasan, dan penjelasan naratif. Penyajian yang baik akan membantu pengguna non-teknis (seperti pembuat kebijakan) dalam memahami makna dari hasil data mining dan menggunakannya sebagai dasar pengambilan keputusan.

2.1.3 Penerapan Data Mining dalam Konteks IPM

Indeks Pembangunan Manusia (IPM) adalah indikator yang digunakan secara internasional untuk mengukur capaian pembangunan manusia dalam tiga dimensi dasar: umur panjang dan hidup sehat (kesehatan), pengetahuan (pendidikan), dan standar hidup layak (ekonomi). Indonesia, melalui BPS, mengukur IPM provinsi berdasarkan tiga indikator utama:

- **Angka Harapan Hidup (AHH):** Menggambarkan aspek kesehatan masyarakat. Semakin tinggi AHH, maka semakin baik pula layanan kesehatan dan kualitas hidup di daerah tersebut.
- **Rata-rata Lama Sekolah (RLS):** Menggambarkan akses dan partisipasi masyarakat dalam pendidikan formal. Indikator ini menunjukkan seberapa lama, rata-rata, masyarakat menjalani pendidikan.
- **Pengeluaran per Kapita (PPP):** Mewakili kemampuan daya beli masyarakat yang mencerminkan tingkat kesejahteraan ekonomi.

Dengan menggunakan data dari ketiga indikator tersebut, kita dapat mengidentifikasi kesamaan karakteristik antarprovinsi, yang kemudian dikelompokkan menggunakan metode data mining. Hasil pengelompokan ini tidak hanya membantu dalam memahami kondisi pembangunan secara makro, tetapi juga bisa digunakan untuk menyusun kebijakan yang lebih adil, berbasis wilayah, dan sesuai dengan kebutuhan daerah.

Misalnya, jika suatu kluster terdiri dari provinsi-provinsi dengan AHH tinggi namun RLS dan PPP rendah, maka intervensi kebijakan yang dibutuhkan lebih banyak diarahkan pada sektor pendidikan dan ekonomi. Sebaliknya, jika terdapat kluster dengan PPP tinggi namun AHH rendah, maka penguatan sektor kesehatan menjadi prioritas.

Dengan demikian, penerapan data mining bukan hanya menjadi kegiatan teknis pengelompokan data, tetapi juga berperan dalam menciptakan landasan yang kuat untuk pembangunan nasional yang lebih merata, efektif, dan tepat sasaran.

2.2 Algoritma yang Digunakan

Dalam penelitian ini, algoritma utama yang digunakan untuk melakukan pengelompokan (clustering) provinsi-provinsi di Indonesia berdasarkan Indeks Pembangunan Manusia (IPM) adalah **K-Means Clustering**. Pemilihan algoritma ini didasarkan pada sifat data yang bersifat numerik dan multidimensi, serta kebutuhan untuk membagi data ke dalam kelompok-kelompok berdasarkan kemiripan karakteristik. Sebelum membahas lebih jauh tentang bagaimana K-Means bekerja, penting terlebih dahulu memahami konsep dasar dari clustering itu sendiri.

2.2.1 Konsep Dasar Clustering

Clustering atau pengelompokan adalah salah satu teknik utama dalam data mining yang termasuk dalam kategori unsupervised learning, yaitu metode pembelajaran tanpa label atau target output yang telah ditentukan sebelumnya. Tujuannya adalah untuk menemukan struktur atau pola tersembunyi dalam data dengan cara mengelompokkan objek-objek yang memiliki karakteristik serupa ke dalam satu grup, dan memisahkan objek-objek yang berbeda ke dalam grup yang lain.

Dalam konteks penelitian ini, setiap provinsi di Indonesia dianggap sebagai satu objek data, dan karakteristiknya dideskripsikan melalui tiga variabel numerik: **Angka Harapan Hidup (AHH)**, **Rata-rata Lama Sekolah (RLS)**, dan **Pengeluaran per Kapita (PPP)**. Ketiga variabel ini mewakili tiga pilar utama dalam pengukuran IPM, yaitu kesehatan, pendidikan, dan ekonomi. Dengan mengelompokkan provinsi-provinsi berdasarkan kesamaan nilai-nilai dalam tiga dimensi tersebut, kita dapat memperoleh wawasan yang lebih dalam tentang pola pembangunan yang ada di berbagai wilayah Indonesia.

2.2.1 Pengertian dan Prinsip Kerja K-Means

K-Means adalah algoritma clustering berbasis partisi yang sangat populer karena kesederhanaan konsepnya, kecepatan komputasinya, dan efektivitasnya dalam menangani data berdimensi banyak. Algoritma ini bertujuan untuk membagi sekumpulan data ke dalam **K buah klaster (cluster)** berdasarkan kedekatan data satu sama lain. Setiap klaster memiliki satu pusat (centroid) yang menjadi representasi dari anggota-anggota klaster tersebut.

Secara prinsip, K-Means bekerja dengan cara meminimalkan **total jarak kuadrat** antara setiap data dengan pusat klaster tempat ia tergolong. Semakin dekat data terhadap pusat klaster, semakin besar kemungkinan data tersebut berada dalam klaster yang tepat. Oleh karena itu, pemilihan dan pembaruan posisi centroid menjadi proses penting dalam iterasi algoritma ini.

Berikut adalah tahapan umum algoritma K-Means:

1. **Menentukan Jumlah Klaster (K):**

Pada tahap awal, peneliti harus menentukan terlebih dahulu berapa jumlah klaster yang diinginkan. Nilai K ini tidak ditentukan oleh algoritma, tetapi ditentukan berdasarkan pertimbangan analisis data atau metode bantu seperti *Elbow Method*.

2. **Inisialisasi Centroid:**

Algoritma akan memilih K buah titik awal (centroid) secara acak dari data yang ada. Titik-titik ini akan menjadi pusat awal dari masing-masing klaster.

3. **Assign Data ke Klaster Terdekat:**

Setiap data akan dihitung jaraknya ke masing-masing centroid menggunakan ukuran jarak tertentu, umumnya **Euclidean Distance**. Data kemudian dimasukkan ke dalam klaster dengan centroid terdekat.

4. **Update Centroid:**

Setelah semua data dikelompokkan, posisi centroid diperbarui berdasarkan rata-rata dari seluruh titik dalam masing-masing kluster. Ini berarti centroid akan bergeser ke pusat “massa” data dalam kluster tersebut.

5. **Iterasi hingga Konvergen:**

Proses pengelompokan dan pembaruan centroid diulang terus menerus hingga tidak ada lagi perubahan signifikan pada komposisi kluster atau posisi centroid. Pada titik ini, algoritma dianggap telah konvergen dan proses dihentikan.

2.2.3 Kelebihan dan Keterbatasan K-Means

Kelebihan utama algoritma K-Means adalah kesederhanaan dan efisiensinya. Algoritma ini relatif cepat dan dapat diimplementasikan dengan mudah dalam berbagai bahasa pemrograman dan perangkat analisis data seperti Python, R, atau MATLAB. Selain itu, K-Means bekerja sangat baik pada data numerik berdimensi rendah hingga sedang, seperti halnya data IPM yang hanya memiliki tiga dimensi utama.

Namun demikian, K-Means juga memiliki beberapa keterbatasan, antara lain:

- **Harus Menentukan Nilai K di Awal:**

Tidak seperti algoritma lain yang bisa menentukan jumlah kluster secara otomatis, K-Means membutuhkan nilai K yang ditentukan terlebih dahulu. Oleh karena itu, metode bantu seperti Elbow Method atau Silhouette Score sangat penting untuk memilih jumlah kluster optimal.

- **Sensitif terhadap Inisialisasi Awal:**

Hasil akhir pengelompokan sangat bergantung pada posisi awal centroid. Inisialisasi yang buruk bisa membuat algoritma konvergen ke solusi lokal yang tidak optimal. Untuk mengatasi ini, biasa digunakan metode seperti *K-Means++* yang menginisialisasi centroid dengan lebih cerdas.

- **Tidak Cocok untuk Kluster Non-Sferis atau Berukuran Tidak Seimbang:**

K-Means mengasumsikan bahwa kluster berbentuk bulat dan memiliki ukuran yang relatif seragam. Jika data tidak memenuhi asumsi ini, hasil pengelompokan bisa menjadi tidak akurat.

2.2.4 Penerapan K-Means dalam Penelitian

Dalam penelitian ini, K-Means digunakan untuk mengelompokkan 34 provinsi di Indonesia berdasarkan tiga variabel input utama:

1. **Angka Harapan Hidup (AHH)** → mewakili dimensi kesehatan.
2. **Rata-rata Lama Sekolah (RLS)** → mewakili dimensi pendidikan.
3. **Pengeluaran per Kapita (PPP)** → mewakili dimensi ekonomi.

Sebelum diterapkan, seluruh data numerik dilakukan proses **normalisasi** terlebih dahulu agar setiap variabel memiliki skala yang setara. Hal ini penting agar algoritma tidak memprioritaskan variabel dengan nilai absolut besar, seperti PPP, yang skalanya bisa jauh lebih besar dibandingkan AHH atau RLS.

Selanjutnya, algoritma K-Means akan mengelompokkan provinsi-provinsi tersebut ke dalam sejumlah klaster berdasarkan nilai-nilai dari ketiga indikator tersebut. Misalnya, satu klaster mungkin terdiri dari provinsi-provinsi dengan AHH dan RLS tinggi tetapi PPP rendah. Klaster lain mungkin terdiri dari provinsi-provinsi dengan semua indikator rendah, yang bisa dianggap sebagai wilayah tertinggal dalam konteks pembangunan manusia.

Untuk menentukan jumlah klaster yang paling optimal, digunakan **Elbow Method**, yaitu metode grafis yang melihat titik “tekukan” dalam grafik nilai inertia terhadap jumlah klaster. Titik tekukan tersebut menunjukkan jumlah klaster di mana penambahan klaster baru tidak lagi memberikan pengurangan signifikan terhadap nilai total jarak (inertia).

2.2.5 Manfaat Penggunaan K-Means dalam Konteks IPM

Dengan membagi provinsi ke dalam kelompok-kelompok yang memiliki karakteristik pembangunan yang mirip, pemerintah dan pemangku kebijakan dapat memperoleh pemahaman yang lebih tajam tentang pola ketimpangan pembangunan. Hasil klasterisasi dapat digunakan untuk:

- Menyusun program pembangunan berdasarkan kondisi khas tiap klaster.
- Mengalokasikan anggaran atau sumber daya pembangunan secara lebih adil.
- Mengidentifikasi wilayah yang memerlukan perhatian khusus di sektor tertentu (kesehatan, pendidikan, atau ekonomi).
- Mengembangkan kebijakan yang terfokus dan kontekstual, tidak lagi bersifat generalisasi nasional.

Dengan demikian, algoritma K-Means bukan hanya menjadi alat analisis data, tetapi juga dapat dijadikan instrumen strategis dalam proses perencanaan pembangunan nasional yang berbasis data dan bukti (*data-driven policy making*).

BAB 3. METODOLOGI PENELITIAN

3.1 Data Science Methodology

Metode penelitian yang digunakan dalam studi ini merupakan metode sistematis yang bertujuan untuk menjawab pertanyaan penelitian secara objektif serta memahami urutan langkah-langkah analisis secara terstruktur. Dalam penelitian ini, digunakan algoritma K-means untuk melakukan pengelompokan provinsi-provinsi di Indonesia berdasarkan Indeks Pembangunan Manusia (IPM).

Algoritma K-means merupakan metode klustering berbasis partisi yang membagi data ke dalam sejumlah kelompok (cluster) yang tidak saling tumpang tindih. Algoritma ini bekerja dengan menentukan sejumlah pusat cluster (centroid) secara acak pada awalnya, kemudian secara iteratif melakukan dua langkah utama:

1. Menetapkan keanggotaan cluster: Setiap titik data ditugaskan ke cluster yang memiliki centroid terdekat berdasarkan jarak (umumnya jarak Euclidean).
2. Memperbarui centroid: Rata-rata posisi titik-titik data dalam masing-masing cluster dihitung untuk mendapatkan centroid baru.

Proses ini berlangsung secara berulang hingga posisi centroid tidak berubah lagi secara signifikan atau jumlah iterasi maksimum tercapai. Setiap titik data selalu menjadi bagian dari satu cluster pada suatu iterasi, tetapi dapat berpindah ke cluster lain pada iterasi berikutnya tergantung pada kedekatan dengan centroid yang diperbarui.

3.2 Data Preparation

Tahap persiapan data merupakan bagian penting dalam metodologi data science, karena kualitas data sangat mempengaruhi hasil analisis. Dalam penelitian ini, data yang digunakan adalah data **Indeks Pembangunan Manusia (IPM)** dari setiap provinsi di Indonesia, yang diperoleh dari publikasi resmi **Badan Pusat Statistik (BPS)**. Variabel utama yang dianalisis meliputi:

- **Angka Harapan Hidup (AHH)** – mewakili aspek kesehatan.
- **Rata-rata Lama Sekolah (RLS)** – mewakili aspek pendidikan.
- **Pengeluaran Per Kapita (PPP)** – mewakili aspek ekonomi.

Sebelum dilakukan pemodelan, data mengalami beberapa proses praproses, antara lain:

1. Pembersihan Data (Data Cleaning)

Nilai kosong, duplikat, atau tidak valid diidentifikasi dan diatasi. Pada kasus ini, karena sumber berasal dari BPS, data relatif bersih, namun tetap dilakukan verifikasi awal.

2. Normalisasi Data

Karena ketiga variabel memiliki skala yang berbeda (misalnya, nilai PPP jauh lebih besar daripada AHH dan RLS), maka dilakukan normalisasi menggunakan metode **min-max**

scaling untuk menyamakan skala antar fitur, sesuai dengan kebutuhan algoritma K-Means yang sensitif terhadap skala data (Han et al., 2011).

3.3 Modeling with K-Means

Setelah data disiapkan, proses pemodelan dilakukan dengan menggunakan algoritma K-Means. Pemilihan jumlah kluster (K) ditentukan menggunakan pendekatan **Elbow Method**, yaitu metode visualisasi grafik antara jumlah kluster dan nilai total inertia (dalam hal ini, **Within-Cluster Sum of Squares - WCSS**) untuk menentukan titik optimal.

Langkah-langkah implementasi model K-Means meliputi:

Menentukan Nilai K Optimal

Dengan memplot nilai inertia terhadap berbagai nilai K , titik “tekukan” pada grafik dianggap sebagai jumlah kluster optimal (Ketchen & Shook, 1996).

Inisialisasi Centroid dan Iterasi

Menggunakan metode **K-Means++** untuk menginisialisasi centroid secara lebih baik dan menghindari konvergensi pada solusi lokal (Arthur & Vassilvitskii, 2007).

Proses Klusterisasi

Data dipetakan ke kluster-kluster berdasarkan kemiripan fitur (menggunakan jarak Euclidean). Proses dilakukan berulang hingga centroid stabil.

3.4 Evaluation and Interpretation

Evaluasi hasil klusterisasi dilakukan baik secara kuantitatif maupun kualitatif. Secara kuantitatif, digunakan **Silhouette Coefficient** untuk mengukur seberapa baik pemisahan antar kluster. Semakin tinggi nilai koefisien, semakin baik kualitas kluster yang terbentuk (Rousseeuw, 1987).

Secara kualitatif, setiap kluster dianalisis berdasarkan **rata-rata nilai indikator dalam kluster tersebut**, sehingga dapat diinterpretasikan maknanya. Misalnya:

- Kluster 1: Provinsi dengan AHH dan RLS tinggi namun PPP rendah.
- Kluster 2: Provinsi dengan semua indikator rendah.
- Kluster 3: Provinsi dengan semua indikator tinggi.

Interpretasi ini membantu dalam menyusun kebijakan berbasis kluster, misalnya pemberian prioritas program pembangunan pada kluster yang tertinggal.

BAB 4. PENGUMPULAN DAN PENGOLAHAN DATA

4.1 Pengumpulan Data

Langkah awal dalam proses penelitian ini dimulai dari pengumpulan data yang menjadi dasar atau fondasi utama bagi seluruh tahapan analisis selanjutnya. Data yang digunakan dalam penelitian ini semuanya bersumber dari **Badan Pusat Statistik (BPS)**, lembaga resmi pemerintah Indonesia yang menyediakan data statistik nasional secara berkala dan terpercaya. Pemilihan BPS sebagai sumber data dilakukan dengan pertimbangan bahwa data yang disajikan oleh BPS telah melalui proses verifikasi dan validasi yang ketat, sehingga dapat dipertanggungjawabkan keakuratannya.

Data yang dikumpulkan berfokus pada **Indeks Pembangunan Manusia (IPM)** provinsi-provinsi di Indonesia, yang mencerminkan pencapaian pembangunan manusia dari tiga dimensi utama, yaitu:

- **Kesehatan**, yang diwakili oleh **Angka Harapan Hidup (AHH)**
- **Pendidikan**, yang diukur melalui dua indikator yaitu **Rata-rata Lama Sekolah (RLS)**
- **Standar hidup layak**, yang diwakili oleh **Pengeluaran per Kapita yang disesuaikan (PPP)**.

Seluruh data indikator tersebut diunduh dalam bentuk dataset melalui situs resmi BPS (<https://bps.go.id>) dalam format **Microsoft Excel (XLSX)** dan **Comma-Separated Values (CSV)**. Pengumpulan data dilakukan dengan memilih tahun terbaru yang tersedia secara lengkap untuk seluruh provinsi, agar hasil analisisnya dapat merefleksikan kondisi pembangunan manusia secara aktual.

Selama proses pengumpulan data, dilakukan pemeriksaan awal terhadap **kelengkapan dan konsistensi data**. Beberapa provinsi baru seperti Kalimantan Utara dan Papua Barat Daya diperhatikan secara khusus untuk memastikan bahwa data mereka tidak tertinggal atau memiliki pola anomali akibat pemekaran wilayah. Selain itu, dipastikan bahwa setiap provinsi memiliki entri yang valid untuk keempat indikator utama yang dibutuhkan dalam proses pengelompokan menggunakan algoritma K-Means.

Data yang berhasil dikumpulkan kemudian disimpan dalam format yang siap digunakan untuk proses **preprocessing**, termasuk proses normalisasi, transformasi, dan analisis kluster selanjutnya. Dengan proses pengumpulan data yang terstruktur dan sumber data yang kredibel, diharapkan hasil akhir dari penelitian ini tidak hanya akurat secara teknis, tetapi juga relevan secara kebijakan.

4.2 Pengolahan Data

Sebelumnya kami menggunakan beberapa library seperti :

```
# Import semua library yang dibutuhkan
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, davies_bouldin_score
```

4.2.1 Data Preparation

```
# 1. DATA PREPARATION

# Membaca data dari file Excel
df_raw = pd.read_excel(
    "/home/kou/Documents/Data Mining/Datasets/Data Preprocessing.xlsx",
    skiprows=2
)

# Rename kolom agar lebih mudah digunakan
df_raw.columns = [
    "Provinsi", "Pengeluaran_2023", "_ignore1", "Pengeluaran_2024",
    "_ignore2",
    "RLS_2023", "_ignore3", "_ignore4", "RLS_2024", "_ignore5", "_ignore6",
    "AHH_L_2023", "_ignore7", "AHH_P_2023", "_ignore8", "AHH_L_2024",
    "_ignore9", "AHH_P_2024"
]

# Pilih hanya kolom yang relevan dan hapus baris tanpa nama provinsi
df = df_raw[[
    "Provinsi", "Pengeluaran_2023", "Pengeluaran_2024",
    "RLS_2023", "RLS_2024", "AHH_L_2023", "AHH_P_2023", "AHH_L_2024",
    "AHH_P_2024"
]].dropna(subset=["Provinsi"]).reset_index(drop=True)

print("Contoh data awal:")
display(df.head())
```

#Output

Contoh data awal:

	Provinsi	Pengeluaran_2023	Pengeluaran_2024	RLS_2023	RLS_2024	AHH_L_2023	AHH_P_2023	AHH_L_2024	AHH_P_2024
0	ACEH	10334	10811	9.89	9.95	71.04	75.18	71.14	75.37
1	SUMATERA UTARA	11049	11460	10.07	10.18	71.44	76.01	71.59	76.32
2	SUMATERA BARAT	11380	11718	9.59	9.72	71.75	76.65	71.90	76.97
3	RIAU	11448	11857	9.6	9.69	71.77	76.71	71.92	77.02
4	JAMBI	11160	11621	9.16	9.26	71.55	76.24	71.70	76.55

4.2.2 Data Preprocessing

```
# 2. DATA PREPROCESSING

# Hapus baris agregat nasional (INDONESIA)
df = df[df["Provinsi"].str.upper() != "INDONESIA"].reset_index(drop=True)

# Ubah semua kolom numerik ke tipe data float
for col in df.columns[1:]:
    df[col] = pd.to_numeric(df[col], errors='coerce')

# Hitung rata-rata angka harapan hidup (AHH) laki-laki dan perempuan untuk
tiap tahun
df["AHH_2023"] = (df["AHH_L_2023"] + df["AHH_P_2023"]) / 2
df["AHH_2024"] = (df["AHH_L_2024"] + df["AHH_P_2024"]) / 2

# Mapping provinsi ke pulau untuk analisis regional
pulau_dict = {
    "SUMATERA": [
        "ACEH", "SUMATERA UTARA", "SUMATERA BARAT", "RIAU", "JAMBI",
        "SUMATERA SELATAN",
        "BENGKULU", "LAMPUNG", "KEPULAUAN BANGKA BELITUNG", "KEP. BANGKA
        BELITUNG", "KEPULAUAN RIAU"
    ],
    "JAWA": [
        "DKI JAKARTA", "JAWA BARAT", "JAWA TENGAH", "D I YOGYAKARTA", "JAWA
        TIMUR", "BANTEN"
    ],
    "KEPULAUAN NUSA TENGGARA": [
        "BALI", "NUSA TENGGARA BARAT", "NUSA TENGGARA TIMUR"
    ],
    "KALIMANTAN": [
        "KALIMANTAN BARAT", "KALIMANTAN TENGAH", "KALIMANTAN SELATAN",
        "KALIMANTAN TIMUR", "KALIMANTAN UTARA"
    ],
    "SULAWESI": [
        "SULAWESI UTARA", "SULAWESI TENGAH", "SULAWESI SELATAN",
        "SULAWESI TENGGARA", "GORONTALO", "SULAWESI BARAT"
    ],
    "MALUKU": [
        "MALUKU", "MALUKU UTARA"
    ],
    "PAPUA": [
        "PAPUA", "PAPUA BARAT", "PAPUA TENGAH", "PAPUA PEGUNUNGAN",
        "PAPUA SELATAN", "PAPUA BARAT DAYA"
    ]
}

pulau_map = {prov: pulau for pulau, prov_list in pulau_dict.items() for prov
in prov_list}
df["Pulau"] = df["Provinsi"].str.upper().map(pulau_map)
```

```
# Cek apakah ada provinsi yang belum berhasil dipetakan ke pulau
unmapped = df[df["Pulau"].isnull()][ "Provinsi"].unique()
if len(unmapped) > 0:
    print("Provinsi yang tidak terpetakan ke pulau:", unmapped)

# Cek missing value sebelum dilakukan imputasi
print("Missing value per kolom sebelum imputasi:")
display(df.isnull().sum().to_frame("Jumlah Missing Value"))

# Imputasi nilai kosong dengan rata-rata per pulau (hanya untuk data yang sudah punya pulau)
num_cols = df.select_dtypes(include=[np.number]).columns
for col in num_cols:
    df.loc[df["Pulau"].notnull(), col] =
df[df["Pulau"].notnull()].groupby("Pulau")[col].transform(lambda x:
x.fillna(x.mean()))

print("\nMissing value per kolom setelah imputasi:")
display(df.isnull().sum().to_frame("Jumlah Missing Value"))

if df.isnull().any().any():
    print("\nData yang masih bermasalah:")
    display(df[df.isnull().any(axis=1)])

print("\nRingkasan statistik data setelah preprocessing:")
display(df.describe())
```

#Output

Missing value per kolom sebelum imputasi:

Jumlah Missing Value	
Provinsi	0
Pengeluaran_2023	4
Pengeluaran_2024	0
RLS_2023	4
RLS_2024	0
AHH_L_2023	4
AHH_P_2023	4
AHH_L_2024	0
AHH_P_2024	0
AHH_2023	4
AHH_2024	0
Pulau	0

Missing value per kolom setelah imputasi:

Jumlah Missing Value	
Provinsi	0
Pengeluaran_2023	0
Pengeluaran_2024	0
RLS_2023	0
RLS_2024	0
AHH_L_2023	0
AHH_P_2023	0
AHH_L_2024	0
AHH_P_2024	0
AHH_2023	0
AHH_2024	0
Pulau	0

Ringkasan statistik data setelah preprocessing:

	Pengeluaran_2023	Pengeluaran_2024	RLS_2023	RLS_2024	AHH_L_2023	AHH_P_2023	AHH_L_2024	AHH_P_2024	AHH_2023	AHH_2024
count	38.000000	38.000000	38.000000	38.000000	38.000000	38.000000	38.000000	38.000000	38.000000	38.000000
mean	11103.236842	11591.973684	9.243947	9.292368	70.461316	74.921842	70.678158	75.224211	72.691579	72.951184
std	2398.629343	2463.450135	0.792777	1.148888	2.183568	2.567711	2.114524	2.558893	2.366521	2.328161
min	7562.000000	5707.000000	7.340000	5.100000	66.230000	70.210000	65.460000	69.420000	68.220000	67.440000
25%	9722.000000	10236.250000	8.725000	8.785000	68.840000	72.780000	69.112500	73.062500	70.810000	71.087500
50%	11127.500000	11613.500000	9.160000	9.340000	71.425000	75.985000	71.570000	76.275000	73.705000	73.922500
75%	11868.750000	12296.250000	9.710000	9.930000	71.770000	76.680000	71.917500	76.985000	74.237500	74.465000
max	19373.000000	19953.000000	11.420000	11.490000	73.480000	78.750000	73.560000	78.960000	75.880000	76.060000

4.2.3 Splitting Data

```
# 3. SPLITTING DATA

# Siapkan data fitur untuk clustering, masing-masing tahun sebagai observasi terpisah
fitur_2023 = df[["Provinsi", "Pengeluaran_2023", "RLS_2023", "AHH_2023"]].copy()
fitur_2023["Tahun"] = 2023
fitur_2023.columns = ["Provinsi", "Pengeluaran", "RLS", "AHH", "Tahun"]

fitur_2024 = df[["Provinsi", "Pengeluaran_2024", "RLS_2024", "AHH_2024"]].copy()
fitur_2024["Tahun"] = 2024
fitur_2024.columns = ["Provinsi", "Pengeluaran", "RLS", "AHH", "Tahun"]

fitur = pd.concat([fitur_2023, fitur_2024], ignore_index=True)
```

4.2.4 Model Development

```
# 4. MODEL DEVELOPMENT

# HITUNG IPM
def hitung_ipm(ahh, rls, ppp):
    indeks_ahh = (ahh - 20) / (85 - 20)
    indeks_pendidikan = rls / 15
    indeks_pendapatan = (np.log(ppp) - np.log(100)) / (np.log(75000) - np.log(100))
    ipm = (indeks_ahh * indeks_pendidikan * indeks_pendapatan) ** (1/3) * 100
    return ipm

df["IPM_2023"] = df.apply(lambda row: hitung_ipm(row["AHH_2023"], row["RLS_2023"], row["Pengeluaran_2023"]), axis=1)
df["IPM_2024"] = df.apply(lambda row: hitung_ipm(row["AHH_2024"], row["RLS_2024"], row["Pengeluaran_2024"]), axis=1)
df["Delta_IPM"] = df["IPM_2024"] - df["IPM_2023"]

# Standarisasi fitur sebelum clustering
scaler = StandardScaler()
scaled_fitur = scaler.fit_transform(fitur[["Pengeluaran", "RLS", "AHH"]])

# Jalankan KMeans pada seluruh data fitur
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
fitur["Cluster"] = kmeans.fit_predict(scaled_fitur)

# Relabel cluster supayaurut dari IPM terendah ke tertinggi di masing-masing tahun
```

```
def relabel_cluster(fitur, df, tahun, ipm_col):
    temp = fitur[fitur["Tahun"] == tahun].copy()
    temp = temp.merge(df[["Provinsi", ipm_col]], on="Provinsi", how="left")
    cluster_means = temp.groupby("Cluster")[ipm_col].mean().sort_values()
    mapping = {old: new for new, old in enumerate(cluster_means.index)}
    return fitur.loc[fitur["Tahun"] == tahun,
"Cluster"].map(mapping).astype(int)

fitur.loc[fitur["Tahun"] == 2023, "Cluster"] = relabel_cluster(fitur, df,
2023, "IPM_2023")
fitur.loc[fitur["Tahun"] == 2024, "Cluster"] = relabel_cluster(fitur, df,
2024, "IPM_2024")

# Masukkan label cluster ke dataframe utama
df = df.merge(
    fitur[fitur["Tahun"] == 2023][["Provinsi",
"Cluster"]].rename(columns={"Cluster": "Cluster_2023"}),
    on="Provinsi", how="left"
)
df = df.merge(
    fitur[fitur["Tahun"] == 2024][["Provinsi",
"Cluster"]].rename(columns={"Cluster": "Cluster_2024"}),
    on="Provinsi", how="left"
)
```

4.2.5 Matrix Evaluation

```
# 5. MATRIX EVALUATION

# Tabel ringkasan IPM dan cluster
tabel_ringkasan = df[[
    "Provinsi", "Pulau",
    "IPM_2023", "Cluster_2023",
    "IPM_2024", "Cluster_2024",
    "Delta_IPM"
]].sort_values("IPM_2024", ascending=False).reset_index(drop=True)

print("Tabel ringkasan IPM dan cluster 2023-2024:")
display(tabel_ringkasan)

print("\nRata-rata IPM 2023 per cluster:")
display(df.groupby("Cluster_2023")["IPM_2023"].mean())
print("\nRata-rata IPM 2024 per cluster:")
display(df.groupby("Cluster_2024")["IPM_2024"].mean())

# Evaluasi kualitas clustering pada seluruh data fitur
silhouette = silhouette_score(scaled_fitur, fitur["Cluster"])
dbi = davies_bouldin_score(scaled_fitur, fitur["Cluster"])
```

```
print(f"\nSilhouette Score: {silhouette:.3f}")
print(f"Davies-Bouldin Index: {dbi:.3f}")
```

#Output

Tabel ringkasan IPM dan cluster 2023-2024:

	Provinsi	Pulau	IPM_2023	Cluster_2023	IPM_2024	Cluster_2024	Delta_IPM
0	DKI JAKARTA	JAWA	80.449765	2	80.850665	2	0.400900
1	KEPULAUAN RIAU	SUMATERA	76.568787	2	77.172866	2	0.604079
2	D I YOGYAKARTA	JAWA	75.827401	2	76.309430	2	0.482028
3	KALIMANTAN TIMUR	KALIMANTAN	74.980064	2	75.445557	2	0.465493
4	BALI	KEPULAUAN NUSA TENGGARA	74.407520	2	75.022913	2	0.615393
5	SUMATERA UTARA	SUMATERA	73.332597	1	73.893745	1	0.561149
6	SULAWESI UTARA	SULAWESI	73.304642	1	73.825063	1	0.520421
7	BANTEN	JAWA	73.030763	1	73.493497	1	0.462734
8	PAPUA	PAPUA	61.902014	0	73.304343	0	11.402329
9	RIAU	SUMATERA	72.584881	1	73.093311	1	0.508430
10	SUMATERA BARAT	SUMATERA	72.511426	1	73.092728	1	0.581302
11	ACEH	SUMATERA	72.268007	1	72.713997	1	0.445991
12	JAWA BARAT	JAWA	71.887469	1	72.402751	1	0.515282
13	MALUKU	MALUKU	71.652755	0	72.127623	0	0.474868
14	KALIMANTAN SELATAN	KALIMANTAN	71.426404	1	71.870763	1	0.444360
15	BENGKULU	SUMATERA	71.347891	1	71.811335	1	0.463443
16	SULAWESI SELATAN	SULAWESI	71.278559	1	71.808651	1	0.530091
17	JAMBI	SUMATERA	71.178744	1	71.742441	1	0.563696
18	KALIMANTAN UTARA	KALIMANTAN	71.287791	1	71.666411	1	0.378620
19	KALIMANTAN TENGAH	KALIMANTAN	71.123765	1	71.645554	1	0.521789
20	SULAWESI TENGGARA	SULAWESI	70.918142	0	71.499592	1	0.581450
21	PAPUA BARAT DAYA	PAPUA	65.961106	0	71.359164	0	5.398058
22	KEP. BANGKA BELITUNG	SUMATERA	70.844961	1	71.297155	1	0.452193
23	SUMATERA SELATAN	SUMATERA	70.725425	1	71.260689	1	0.535265
24	JAWA TIMUR	JAWA	70.477723	1	71.166488	1	0.688765
25	LAMPUNG	SUMATERA	69.987721	1	70.517578	1	0.529857
26	JAWA TENGAH	JAWA	70.095350	1	70.454754	1	0.359405
27	MALUKU UTARA	MALUKU	69.726780	0	70.352352	0	0.625572
28	SULAWESI TENGAH	SULAWESI	69.427542	0	69.845340	0	0.417798
29	PAPUA BARAT	PAPUA	69.661565	0	69.259890	0	-0.401675
30	NUSA TENGGARA BARAT	KEPULAUAN NUSA TENGGARA	68.308181	1	68.926766	1	0.618585
31	GORONTALO	SULAWESI	67.864411	0	68.590572	0	0.726161
32	KALIMANTAN BARAT	KALIMANTAN	67.833232	1	68.484236	1	0.651003
33	SULAWESI BARAT	SULAWESI	67.350231	0	67.924667	0	0.574436
34	PAPUA SELATAN	PAPUA	65.961106	0	67.638848	0	1.677742
35	NUSA TENGGARA TIMUR	KEPULAUAN NUSA TENGGARA	66.437601	0	67.169629	0	0.732028
36	PAPUA TENGAH	PAPUA	65.961106	0	58.569228	0	-7.391878
37	PAPUA PEGUNUNGAN	PAPUA	65.961106	0	53.320740	0	-12.640365

```
Rata-rata IPM 2023 per cluster:

Cluster_2023
0    67.598882
1    71.241777
2    76.446707
Name: IPM_2023, dtype: float64

Rata-rata IPM 2024 per cluster:

Cluster_2024
0    67.455200
1    71.746072
2    76.960286
Name: IPM_2024, dtype: float64

Silhouette Score: 0.410
Davies-Bouldin Index: 0.865
```

4.2.6 Performance Model Evaluation

```
# 6. PERFORMANCE MODEL EVALUATION

# Cek provinsi yang berpindah cluster dari 2023 ke 2024
moved = df[df["Cluster_2023"] != df["Cluster_2024"]]
print(f"\nJumlah provinsi berpindah cluster: {len(moved)}")
display(moved[["Provinsi", "Cluster_2023", "Cluster_2024"]])

print("\nProvinsi dengan IPM Meningkat:")
display(df[df["Delta_IPM"] > 0][["Provinsi", "IPM_2023", "IPM_2024",
"Delta_IPM"]].sort_values("Delta_IPM", ascending=False))

print("\nProvinsi dengan IPM Menurun:")
display(df[df["Delta_IPM"] < 0][["Provinsi", "IPM_2023", "IPM_2024",
"Delta_IPM"]].sort_values("Delta_IPM"))

#Output

Jumlah provinsi berpindah cluster: 1

Provinsi Cluster_2023 Cluster_2024
27 SULAWESI TENGGARA      0         1
```

Provinsi dengan IPM Meningkat:

	Provinsi	IPM_2023	IPM_2024	Delta_IPM
34	PAPUA	61.902014	73.304343	11.402329
33	PAPUA BARAT DAYA	65.961106	71.359164	5.398058
35	PAPUA SELATAN	65.961106	67.638848	1.677742
18	NUSA TENGGARA TIMUR	66.437601	67.169629	0.732028
28	GORONTALO	67.864411	68.590572	0.726161
14	JAWA TIMUR	70.477723	71.166488	0.688765
19	KALIMANTAN BARAT	67.833232	68.484236	0.651003
31	MALUKU UTARA	69.726780	70.352352	0.625572
17	NUSA TENGGARA BARAT	68.308181	68.926766	0.618585
16	BALI	74.407520	75.022913	0.615393
9	KEPULAUAN RIAU	76.568787	77.172866	0.604079
27	SULAWESI TENGGARA	70.918142	71.499592	0.581450
2	SUMATERA BARAT	72.511426	73.092728	0.581302
29	SULAWESI BARAT	67.350231	67.924667	0.574436
4	JAMBI	71.178744	71.742441	0.563696
1	SUMATERA UTARA	73.332597	73.893745	0.561149
5	SUMATERA SELATAN	70.725425	71.260689	0.535265
26	SULAWESI SELATAN	71.278559	71.808651	0.530091
7	LAMPUNG	69.987721	70.517578	0.529857
20	KALIMANTAN TENGAH	71.123765	71.645554	0.521789
24	SULAWESI UTARA	73.304642	73.825063	0.520421
11	JAWA BARAT	71.887469	72.402751	0.515282
3	RIAU	72.584881	73.093311	0.508430
13	D I YOGYAKARTA	75.827401	76.309430	0.482028
30	MALUKU	71.652755	72.127623	0.474868
22	KALIMANTAN TIMUR	74.980064	75.445557	0.465493
6	BENGKULU	71.347891	71.811335	0.463443
15	BANTEN	73.030763	73.493497	0.462734
8	KEP. BANGKA BELITUNG	70.844961	71.297155	0.452193
0	ACEH	72.268007	72.713997	0.445991
21	KALIMANTAN SELATAN	71.426404	71.870763	0.444360
25	SULAWESI TENGAH	69.427542	69.845340	0.417798
10	DKI JAKARTA	80.449765	80.850665	0.400900
23	KALIMANTAN UTARA	71.287791	71.666411	0.378620
12	JAWA TENGAH	70.095350	70.454754	0.359405

Provinsi dengan IPM Menurun:

	Provinsi	IPM_2023	IPM_2024	Delta_IPM
37	PAPUA PEGUNUNGAN	65.961106	53.320740	-12.640365
36	PAPUA TENGAH	65.961106	58.569228	-7.391878
32	PAPUA BARAT	69.661565	69.259890	-0.401675

4.2.6 Visualization

```
# VISUALIZATION

import matplotlib.patches as mpatches
```

```

# Palet warna cluster
palette = sns.color_palette("Set2", n_colors=df["Cluster_2024"].nunique())
cluster_labels = [f"Cluster {i}" for i in sorted(df['Cluster_2024'].unique())]
cluster_color_map = {i: palette[i] for i in
sorted(df['Cluster_2024'].unique())}

# 1. Barplot Perbandingan IPM 2023 & 2024 per Provinsi
df_sorted = df.sort_values("IPM_2024", ascending=True)
plt.figure(figsize=(15, 10))
bar_width = 0.4
y = np.arange(len(df_sorted))
cluster_colors = df_sorted["Cluster_2024"].map(cluster_color_map)

plt.barh(y - bar_width/2, df_sorted["IPM_2023"], height=bar_width,
color="#b3cde3", label="IPM 2023", alpha=0.85)
plt.barh(y + bar_width/2, df_sorted["IPM_2024"], height=bar_width,
color=cluster_colors, label="IPM 2024 (by Cluster)", alpha=0.95)

for i, (ipm23, ipm24) in enumerate(zip(df_sorted["IPM_2023"],
df_sorted["IPM_2024"])):
    plt.text(ipm23 - 0.5, i - bar_width/2, f"{ipm23:.2f}", va='center',
fontsize=9, color="#225577", ha='right')
    plt.text(ipm24 + 0.5, i + bar_width/2, f"{ipm24:.2f}", va='center',
fontsize=9, color="#a33c00", ha='left')

plt.yticks(y, df_sorted["Provinsi"], fontsize=11)
plt.xlabel("Nilai IPM", fontsize=12)
plt.title("Perbandingan IPM Provinsi Tahun 2023 dan 2024\n(Warna IPM 2024
Berdasarkan Cluster 2024)", fontsize=14, weight='bold')

# Custom legend
handles = [mpatches.Patch(color=palette[i], label=cluster_labels[i]) for i in
range(len(cluster_labels))]
plt.legend(handles=handles + [mpatches.Patch(color="#b3cde3", label="IPM
2023")], fontsize=11, loc='lower right')
plt.grid(axis='x', linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()

# 2. Scatter Plot IPM 2023 vs 2024
plt.figure(figsize=(10,7))
sns.scatterplot(
    x="IPM_2023", y="IPM_2024",
    hue="Cluster_2024", palette=palette, data=df, s=120, edgecolor="k"
)
for i, row in df.iterrows():
    plt.text(row["IPM_2023"]+0.1, row["IPM_2024"]+0.1, row["Provinsi"],
fontsize=8, alpha=0.7)
plt.plot([df["IPM_2023"].min(), df["IPM_2024"].max()],
[ df["IPM_2023"].min(), df["IPM_2024"].max()], 'k--', lw=1)
plt.title("Scatter Plot IPM 2023 vs 2024\n(Warna Titik Berdasarkan Cluster

```



```


2024)", fontsize=14, weight='bold')
plt.xlabel("IPM 2023", fontsize=12)
plt.ylabel("IPM 2024", fontsize=12)
plt.legend(title="Cluster 2024", fontsize=10)
plt.tight_layout()
plt.show()

# 3. Barplot Delta IPM per Provinsi
df_delta = df.sort_values("Delta_IPM", ascending=False)
plt.figure(figsize=(13,8))
bar = sns.barplot(
    x="Delta_IPM", y="Provinsi",
    data=df_delta,
    hue="Cluster_2024", dodge=False, palette=palette
)
for i, (delta, prov) in enumerate(zip(df_delta["Delta_IPM"],
df_delta["Provinsi"])):
    plt.text(delta + (0.05 if delta > 0 else -0.05), i, f"{delta:+.2f}",
            va='center', ha='left' if delta > 0 else 'right', fontsize=9,
            color="#333")
plt.title("Perubahan (Delta) IPM 2024 vs 2023 per Provinsi\n(Warna Berdasarkan
Cluster 2024)", fontsize=14, weight='bold')
plt.xlabel("Delta IPM (2024 - 2023)", fontsize=12)
plt.ylabel("Provinsi", fontsize=12)
plt.axvline(0, color='k', linestyle='--', lw=1)
plt.legend(title="Cluster 2024", fontsize=10)
plt.tight_layout()
plt.show()

#Output

```



BAB 5. ANALISIS DAN PEMBAHASAN

5.1 Hasil Klasterisasi K-Means

Penelitian ini menggunakan algoritma K-Means untuk mengelompokkan 38 provinsi di Indonesia berdasarkan nilai Indeks Pembangunan Manusia (IPM) pada tahun 2023 dan 2024. Sebelum proses klasterisasi dilakukan, peneliti menentukan jumlah klaster optimal dengan menggunakan metode Elbow. Hasil dari metode tersebut menunjukkan bahwa nilai k optimal adalah 3, karena pada titik ini penurunan nilai inertia mulai melambat, menandakan bahwa penambahan jumlah klaster tidak lagi memberikan peningkatan signifikan dalam kualitas pemisahan data.

Setelah menentukan jumlah klaster, dilakukan proses klasterisasi terhadap data IPM. Hasil klasterisasi membagi provinsi ke dalam tiga klaster berbeda:

- **Klaster 0:** Provinsi dengan nilai IPM terendah
- **Klaster 1:** Provinsi dengan nilai IPM sedang
- **Klaster 2:** Provinsi dengan nilai IPM tertinggi

Visualisasi hasil klasterisasi menggunakan scatter plot menunjukkan pemisahan yang cukup jelas antar klaster. Pusat klaster (centroid) pada masing-masing kelompok menandakan rata-rata IPM provinsi dalam klaster tersebut. Hal ini menjadi dasar untuk melakukan interpretasi lebih lanjut terhadap pola pembangunan manusia di Indonesia.

5.2 Komposisi Klaster

Komposisi klaster menunjukkan distribusi tingkat pembangunan manusia di seluruh Indonesia. Berdasarkan hasil klasterisasi:

- **Klaster 2** terdiri dari provinsi-provinsi dengan pembangunan manusia yang tergolong sangat tinggi. Contoh provinsi dalam klaster ini adalah **DKI Jakarta, Bali, DI Yogyakarta, Kepulauan Riau, dan Kalimantan Timur**. Provinsi-provinsi ini secara konsisten menunjukkan nilai IPM di atas 74, yang mencerminkan kualitas hidup yang baik dalam aspek pendidikan, kesehatan, dan ekonomi.
- **Klaster 1** adalah klaster dengan provinsi-provinsi yang memiliki IPM sedang, berkisar antara 70 hingga 74. Sebagian besar provinsi di Indonesia berada dalam klaster ini, mencerminkan bahwa pembangunan di daerah-daerah ini telah berjalan dengan baik, namun masih memiliki ruang untuk perbaikan lebih lanjut.
- **Klaster 0** merupakan klaster dengan IPM terendah. Provinsi dalam klaster ini didominasi oleh wilayah dari Indonesia Timur seperti **Papua, Papua Tengah, Papua Pegunungan, Papua Selatan, dan Nusa Tenggara Timur (NTT)**. IPM provinsi-provinsi ini masih berada di bawah 70, mencerminkan tantangan signifikan dalam pembangunan manusia.

Komposisi ini konsisten dari tahun 2023 ke 2024, meskipun terdapat beberapa perubahan kecil dalam nilai IPM masing-masing provinsi.

5.3 Perubahan IPM dan Dampaknya terhadap Klaster

Secara umum, terdapat peningkatan nilai IPM di sebagian besar provinsi dari tahun 2023 ke 2024. Namun, peningkatan tersebut tidak selalu menyebabkan perpindahan klaster. Hal ini dikarenakan perpindahan klaster dipengaruhi oleh rata-rata IPM pada masing-masing klaster dan posisi relatif provinsi tersebut terhadap pusat klaster.

Salah satu contoh signifikan adalah **Provinsi Papua**, yang mengalami kenaikan IPM sebesar **+11,40 poin**, namun tetap berada di Klaster 0. Hal ini disebabkan oleh jarak nilai IPM Papua terhadap pusat Klaster 1 yang masih cukup jauh, meskipun mengalami peningkatan signifikan secara absolut.

Sebaliknya, **Papua Tengah** dan **Papua Pegunungan** mengalami penurunan IPM cukup tajam, masing-masing sebesar **-7,39** dan **-12,64 poin**. Penurunan ini menyebabkan keduanya semakin jauh dari klaster dengan IPM lebih tinggi dan memperkuat posisinya di Klaster 0.

Hal ini menunjukkan bahwa meskipun nilai IPM bersifat dinamis, perubahan klaster memerlukan perubahan nilai yang cukup besar secara relatif terhadap provinsi lainnya.

5.4 Visualisasi Hasil Klasterisasi

Visualisasi data sangat membantu dalam memahami hasil klasterisasi. Beberapa visualisasi yang digunakan dalam penelitian ini meliputi:

- **Scatter plot** yang menunjukkan hubungan antara IPM tahun 2023 dan 2024. Dari visualisasi ini terlihat bahwa sebagian besar provinsi mengalami peningkatan IPM, ditunjukkan oleh kecenderungan titik bergerak ke arah kanan atas.
- **Bar chart** perubahan IPM antar tahun yang menggambarkan provinsi dengan kenaikan dan penurunan IPM paling signifikan. Visualisasi ini menyoroti kasus ekstrem seperti Papua Pegunungan yang mengalami penurunan tajam, serta Papua yang mencatatkan peningkatan drastis.
- **Peta klasterisasi** yang menunjukkan distribusi provinsi menurut klaster secara geografis. Visualisasi ini menegaskan bahwa wilayah Indonesia bagian timur cenderung terakumulasi dalam Klaster 0, sedangkan wilayah barat dan tengah lebih tersebar di Klaster 1 dan 2.

Visualisasi tersebut memperkuat analisis dan mendukung narasi ketimpangan pembangunan manusia antar wilayah di Indonesia.

5.5 Evaluasi dan Keterbatasan Model

Evaluasi terhadap hasil klasterisasi dilakukan dengan pendekatan interpretatif dan visual. Meskipun algoritma K-Means tidak memiliki label ground truth, hasil yang diperoleh menunjukkan konsistensi dengan kondisi nyata pembangunan manusia di Indonesia.

Namun demikian, model ini memiliki beberapa keterbatasan:

- **Sensitivitas terhadap inisialisasi centroid:** Algoritma K-Means dapat menghasilkan hasil yang berbeda tergantung dari posisi awal centroid. Oleh karena itu, proses klusterisasi dilakukan dengan pengulangan beberapa kali (*n_init*) untuk mengurangi pengaruh tersebut.
- **Tidak mempertimbangkan faktor spasial dan sosial lainnya:** Model ini hanya menggunakan data IPM sebagai variabel masukan, sehingga tidak mempertimbangkan faktor-faktor lain seperti jumlah penduduk, PDB daerah, kondisi geografis, dan kebijakan pembangunan yang bisa mempengaruhi hasil klusterisasi.
- **Anggapan bentuk klaster bulat:** K-Means bekerja optimal untuk data yang memiliki bentuk klaster cenderung bulat (*spherical*), sedangkan distribusi data sosial-ekonomi seperti IPM bisa sangat kompleks dan tidak selalu mengikuti pola tersebut.

5.6 Pola Pembangunan Wilayah Berdasarkan Klaster

Analisis terhadap distribusi klaster menunjukkan adanya ketimpangan pembangunan antar wilayah di Indonesia. **Klaster 2**, yang mewakili pembangunan manusia tertinggi, didominasi oleh provinsi-provinsi dengan akses terhadap infrastruktur dan layanan publik yang baik. Wilayah seperti **DKI Jakarta**, **Yogyakarta**, dan **Bali** mencerminkan keberhasilan pembangunan yang menyeluruh di bidang pendidikan, kesehatan, dan ekonomi.

Klaster 1 mencakup wilayah dengan pembangunan yang cukup baik namun masih belum optimal. Banyak provinsi di Pulau Jawa seperti **Jawa Tengah** dan **Jawa Timur**, serta beberapa wilayah di Sumatera dan Kalimantan, masuk dalam klaster ini. Mereka berada dalam jalur perkembangan yang menjanjikan, namun masih memerlukan peningkatan kualitas layanan publik dan pemerataan pembangunan.

Sementara itu, **Klaster 0** menjadi sorotan utama karena menggambarkan kesenjangan pembangunan yang mencolok, terutama di wilayah timur Indonesia. Tantangan geografis, terbatasnya akses terhadap pendidikan dan layanan kesehatan, serta infrastruktur yang belum memadai, menjadi faktor dominan dalam rendahnya IPM di wilayah ini.

Distribusi klaster ini memberikan masukan penting bagi pengambil kebijakan, bahwa strategi pembangunan manusia perlu disesuaikan secara spesifik untuk tiap wilayah, dengan perhatian khusus pada wilayah yang tertinggal agar pembangunan dapat lebih merata dan inklusif.

BAB 6 KESIMPULAN DAN SARAN

6.1 Kesimpulan

Penelitian ini bertujuan untuk mengelompokkan provinsi-provinsi di Indonesia berdasarkan nilai Indeks Pembangunan Manusia (IPM) pada tahun 2023 dan 2024 menggunakan algoritma K-Means. Berdasarkan hasil analisis dan pembahasan yang telah dilakukan, dapat disimpulkan beberapa poin penting sebagai berikut:

1. **Klasterisasi menggunakan algoritma K-Means berhasil membagi provinsi di Indonesia menjadi tiga klaster** berdasarkan tingkat IPM, yaitu:
 - Klaster 0: Provinsi dengan IPM rendah
 - Klaster 1: Provinsi dengan IPM sedang
 - Klaster 2: Provinsi dengan IPM tinggi
2. **Distribusi provinsi dalam klaster secara geografis menunjukkan pola ketimpangan pembangunan**, di mana sebagian besar provinsi dengan IPM rendah berada di kawasan timur Indonesia, seperti Papua dan Nusa Tenggara Timur, sedangkan provinsi dengan IPM tinggi terkonsentrasi di kawasan barat dan tengah seperti DKI Jakarta, Bali, dan DI Yogyakarta.
3. **Terdapat perubahan nilai IPM dari tahun 2023 ke 2024 di sebagian besar provinsi**, namun tidak semua perubahan tersebut mempengaruhi perpindahan klaster. Ini menunjukkan bahwa meskipun peningkatan IPM terjadi, besar perubahan harus cukup signifikan agar mengubah posisi relatif suatu provinsi terhadap pusat klaster.
4. **Hasil klasterisasi memberikan gambaran objektif mengenai kelompok provinsi yang membutuhkan perhatian lebih dalam pembangunan manusia**, khususnya di bidang pendidikan, kesehatan, dan ekonomi, sehingga pemerintah dapat menyusun kebijakan pembangunan yang lebih terfokus dan berbasis data.
5. **Visualisasi hasil klasterisasi membantu dalam memahami pola dan tren pembangunan manusia di Indonesia**, serta menunjukkan provinsi-provinsi yang mengalami peningkatan atau penurunan IPM secara ekstrem.

Secara keseluruhan, penelitian ini menunjukkan bahwa metode K-Means dapat digunakan secara efektif untuk mengidentifikasi dan menganalisis kelompok-kelompok pembangunan manusia berdasarkan IPM. Hasilnya memberikan wawasan yang bermanfaat dalam konteks perencanaan pembangunan nasional yang lebih adil dan merata.

6.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat disampaikan untuk penelitian selanjutnya maupun untuk pihak-pihak yang berkepentingan, sebagai berikut:

1. **Penelitian di masa depan dapat memasukkan lebih banyak variabel penentu pembangunan manusia**, seperti angka harapan hidup, rata-rata lama sekolah, pengeluaran per kapita, tingkat pengangguran, serta variabel ekonomi dan sosial lainnya, untuk menghasilkan klasterisasi yang lebih komprehensif.
2. **Penggunaan metode klasterisasi lain seperti DBSCAN atau Hierarchical Clustering** dapat dipertimbangkan untuk dibandingkan dengan hasil K-Means, terutama dalam menangani data yang tidak berbentuk bulat atau memiliki outlier signifikan.
3. **Perlu dilakukan analisis lebih lanjut terhadap penyebab perubahan nilai IPM di provinsi tertentu**, khususnya yang mengalami lonjakan atau penurunan ekstrem, seperti Papua dan Papua Pegunungan, untuk memahami faktor-faktor yang mempengaruhi fluktuasi IPM.
4. **Pemerintah dan pemangku kebijakan dapat menggunakan hasil klasterisasi ini sebagai dasar untuk menyusun kebijakan pembangunan yang lebih terarah**, dengan pendekatan diferensiasi kebijakan berdasarkan klaster pembangunan.
5. **Diharapkan adanya pembaruan data IPM secara berkala dan peningkatan kualitas data**, sehingga analisis klasterisasi dan pemodelan data dapat dilakukan secara berkelanjutan untuk mendukung pembangunan berbasis data (data-driven development).

Dengan demikian, hasil penelitian ini tidak hanya memberikan pemetaan kondisi pembangunan manusia saat ini, tetapi juga membuka peluang untuk penelitian lanjutan dan perumusan kebijakan strategis dalam rangka mempercepat pembangunan yang merata dan berkelanjutan di seluruh wilayah Indonesia.

DAFTAR PUSTAKA

- [1] J. Wu, *Advances in k-means clustering: A data mining thinking*. Springer Science & Business Media, 2012.
- [2] M. E. Celebi and K. Aydin, *Unsupervised learning algorithms*. Springer, 2016.
- [3] Mustika *et al.*, *DATA MINING DAN APLIKASINYA*. Penerbit Widina, 2021.
- [4] Mira, S.Kom., M.Kom., Azriel Christian Nurcahyo, S.Kom., M.Kom., Candra Gudiato, S.Kom., M.Kom., Noviyanti. P, S.Kom., M.Kom., and Listra Frigia Missianes Horhoruw, S.Kom., M.Kom., *Data Mining Mengeksplorasi Teknik-Teknik Data Mining dan Metode K-Means Teori, Konsep, Algoritma dan Studi Kasus*. Uwais Inspirasi Indonesia, 2025.
- [5] M. A. M.Kom. S. Si. ., and M. N. M.T. S. T. ., *Data Mining - Algoritma dan Implementasi*. Penerbit Andi, 2020.
- [6] A. Nugrahaini and Rahmadi Yotenka, “Penerapan Algoritma K-Means Clustering untuk Mengelompokkan Kecamatan di Kabupaten Grobogan Menurut Tingkat Kesejahteraan Keluarga Tahun 2020,” *Emerging Statistics and Data Science Journal*, vol. 1, no. 3, pp. 290–299, Dec. 2023, doi: 10.20885/esds.vol1.iss.3.art36.
- [7] 1. Rulin Swastika 2. Siti Mukodimah 3. Ferry Susanto 4. Muhamad Muslihudin 5. Sri Ipinuwati Penerbit Adab, *IMPLEMENTASI DATA MINING (Clustering, Association, Prediction, Estimation, Classification)*. Penerbit Adab.